

{desafío}
latam_

Árboles de Decisión _



Motivación

¿Qué son?

Métodos que buscan particionar el espacio de atributos en una serie de rectángulos y posteriormente se implementa un modelo simple (o estadístico de representación) [Definición de Hastie et al. 2009].


Virtudes:

- Entendibles (a diferencia de los modelos de caja negra como SVM y EM). Por lo general tienen buenos resultados.
- Son no-paramétricos: Encontrarán una solución o representación al problema sin la necesidad de definir componentes estocásticos/sistemáticos (como una regresión lineal).


Defectos:

- Estos buenos resultados tienden a generarse en el training, lo cual induce el overfit.


El proceso de decisión



El proceso de decisión





El proceso de decisión





$$x_1 > s_1$$



El proceso de decisión



El proceso de decisión



El proceso de decisión



Rudimentos

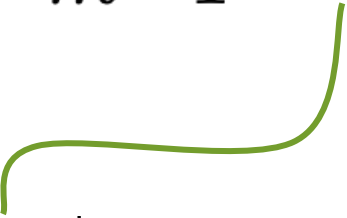
Preliminares

$$\hat{f}(x) = \sum_{m=1}^s c_m \mathbb{I}\left((X_1, X_2) \in \mathbb{R}_m\right)$$

Nuestro objetivo es desarrollar una función de regresión (con constantes) que resuma la subdivisión.

Preliminares


$$\hat{f}(x) = \sum_{m=1}^s c_m \mathbb{I}((X_1, X_2) \in \mathbb{R}_m)$$



c representa la
cantidad de constantes
estimables en el árbol

Preliminares

$$\hat{f}(x) = \sum_{m=1}^s c_m \mathbb{I}\left((X_1, X_2) \in \mathbb{R}_m\right)$$



\mathbb{R} representa las hojas
condicionadas al
subespacio de valores.

Preliminares

$$\hat{f}(x) = \sum_{m=1}^S c_m \mathbb{I}((X_1, X_2) \in \mathbb{R}_m)$$



La sumatoria representa todo el proceso de crear un árbol, donde S va a determinar su profundidad.

Elección de una nueva decisión

$$\mathbb{R}_1(j, s) = \{X | X_j \leq s\} \quad \text{ó} \quad \mathbb{R}_2(j, s) = \{X | X_j \geq s\}$$

Dada una función de regresión que establezca una serie de constantes en un modelo de regresión, la decisión se reduce un problema de optimización greedy donde dado una variable j y un punto de corte s , definimos mitades de plano de manera tal que la elección refleja el puntaje.

Elección de una nueva decisión

$$\mathbb{R}_1(j, s) = \{X | X_j \leq s\} \quad \text{ó} \quad \mathbb{R}_2(j, s) = \{X | X_j \geq s\}$$

Dada una función de regresión que establezca una serie de constantes en un modelo de regresión, la decisión se reduce un problema de optimización greedy donde dado una variable j y un punto de corte s , definimos mitades de plano de manera tal que la elección refleja el puntaje.

Elección de una nueva decisión

$$\mathbb{R}_1(j, s) = \{X | X_j \leq s\} \quad \text{ó} \quad \mathbb{R}_2(j, s) = \{X | X_j \geq s\}$$

Dada una función de regresión que establezca una serie de constantes en un modelo de regresión, la decisión se reduce un problema de optimización greedy donde dado una variable j y un punto de corte s , definimos mitades de plano de manera tal que la elección refleja el puntaje.

Elección de una nueva decisión

$$\mathbb{R}_1(j, s) = \{X | X_j \leq s\} \quad \text{ó} \quad \mathbb{R}_2(j, s) = \{X | X_j \geq s\}$$

Dada una función de regresión que establezca una serie de constantes en un modelo de regresión, la decisión se reduce un problema de optimización greedy donde dado una variable j y un punto de corte s , definimos mitades de plano de manera tal que la elección refleja el puntaje.

Elección de una nueva decisión

$$\mathbb{R}_1(j, s) = \{X | X_j \leq s\} \quad \text{ó} \quad \mathbb{R}_2(j, s) = \{X | X_j \geq s\}$$

Dada una función de regresión que establezca una serie de constantes en un modelo de regresión, la decisión se reduce un problema de optimización greedy donde dado una variable j y un punto de corte s , definimos mitades de plano de manera tal que la elección refleja el puntaje.

Optimización del corte

$$\operatorname{argmin}_{j,s} \left[\operatorname{argmin}_{c_1} \sum_{x_i \in \mathbb{R}} (y_i - c_1)^2 + \operatorname{argmin}_{c_2} \sum_{x_i \in \mathbb{R}} (y_i - c_2)^2 \right]$$

La elección del corte depende a nivel de atributo y la optimización de cada constante candidata generada

Optimización del corte

$$\operatorname{argmin}_{j,s} \left[\operatorname{argmin}_{c_1} \sum_{x_i \in \mathbb{R}} (y_i - c_1)^2 + \operatorname{argmin}_{c_2} \sum_{x_i \in \mathbb{R}} (y_i - c_2)^2 \right]$$



Evaluamos la constante
1 en el subplano de
decisión, minimizando
la impureza

Optimización del corte

$$\operatorname{argmin}_{j,s} \left[\operatorname{argmin}_{c_1} \sum_{x_i \in \mathbb{R}} (y_i - c_1)^2 + \operatorname{argmin}_{c_2} \sum_{x_i \in \mathbb{R}} (y_i - c_2)^2 \right]$$



Evaluamos la constante
2 en el subplano de
decisión, minimizando
la impureza

Optimización del corte

$$\underset{j,s}{\operatorname{argmin}} \left[\underset{c_1}{\operatorname{argmin}} \sum_{x_i \in \mathbb{R}} (y_i - c_1)^2 + \underset{c_2}{\operatorname{argmin}} \sum_{x_i \in \mathbb{R}} (y_i - c_2)^2 \right]$$



Al sumar cada
optimización local,
evaluamos su
comportamiento a nivel
de divisor y atributo

Hiperparámetros

Hiperparámetros asociados

Los hiperparámetros en un árbol de decisión buscan controlar la tendencia de crecer de manera irrestricta:

- ¿Hasta qué punto puedo dejar crecer un árbol?
- ¿Cuántos datos son suficientes en cada nodo para particionar o declararlo terminal?
- ¿Cuántos atributos son suficientes para que mi árbol pueda capturar de buena manera el fenómeno?

Hiperparámetros asociados


- **Máximo de Profundidad:**
Hasta cuándo puede crecer un árbol.
- **Cantidad de atributos:**
Cuántos atributos debo considerar en un árbol.
- **Mínimo de muestras en un nodo particionable:**
Con cuántas observaciones podemos seguir subdividiendo.
- **Mínimo de muestras en un nodo terminal:**
Con cuántas observaciones paramos de subdividir.

Importancia Relativa

- Miden la influencia de un atributo en la decisión del árbol.
- Atributos con una mayor carga se posicionarán antes en el proceso de decisión.
- Cargas altas significan que la división fue más pura.
- **Cargas bajas no significan que el atributo sea irrelevante:** Pueden significar que el modelo no evaluó bien en los atributos.


Impurezas en clasificación

- En un árbol de regresión, el problema se reduce a encontrar una combinación de variable y divisor que reduzca el error cuadrático promedio.
- Para el caso de la clasificación, la medida de impureza conlleva evaluar la tasa de impureza en el modelo.



Impurezas en clasificación


- En un árbol de regresión, el problema se reduce a encontrar una combinación de variable y divisor que reduzca el error cuadrático promedio.
- Para el caso de la clasificación, la medida de impureza conlleva evaluar la tasa de impureza en el modelo.



$$\text{Error de clasificación} = \frac{1}{N_m} \sum_{i \in \mathbb{R}_m} I(y_i \neq k(m)) = 1 - \hat{p}_{mk(m)}$$

Impurezas en clasificación

- En un árbol de regresión, el problema se reduce a encontrar una combinación de variable y divisor que reduzca el error cuadrático promedio.
- Para el caso de la clasificación, la medida de impureza conlleva evaluar la tasa de impureza en el modelo.




$$\text{Gini} = \sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'} = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk})$$

$$\text{Error de clasificación} = \frac{1}{N_m} \sum_{i \in \mathbb{R}_m} I(y_i \neq k(m)) = 1 - \hat{p}_{mk(m)}$$

Impurezas en clasificación

- En un árbol de regresión, el problema se reduce a encontrar una combinación de variable y divisor que reduzca el error cuadrático promedio.
- Para el caso de la clasificación, la medida de impureza conlleva evaluar la tasa de impureza en el modelo.



$$\text{Entropía (o Desviación)} = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

$$\text{Gini} = \sum_{k \neq k'} \hat{p}_{mk} \hat{p}_{mk'} = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk})$$

$$\text{Error de clasificación} = \frac{1}{N_m} \sum_{i \in \mathbb{R}_m} I(y_i \neq k(m)) = 1 - \hat{p}_{mk(m)}$$

{desafío}
latam_

*Academia de
talentos digitales*

www.desafiolatam.com