

**{desafío}**  
**latam\_**

# Mecanismos de Votación \_



# Motivación

# Preliminares

- **Objetivo de los ensambles:** mejorar un modelo particular que represente un fenómeno.
- Hasta el momento, los ensambles se fundamentan en la iteración de un modelo específico:
  - **Ensamblados Paralelos:** Entrenar múltiples instancias de un modelo y posteriormente promediar.
  - **Ensamblados Secuenciales:** Entrenar múltiples instancias de un modelo y corregir de forma iterativa el error predictivo.
- Los ensambles heterogéneos explotan la diversidad de un conjunto de clasificadores débiles para formular un ensamble complejo.

# Razones Fundamentales de la Combinación

- Existe una serie de razones para implementar ensambles heterogéneos.
- Éstas se representan en las **razones fundamentales de combinación algorítmica**.
- Diettrich (2000): *Los métodos combinatorios de algoritmos permite fortalecer el proceso de generalización dada tres razones:*
  - Poder Representacional.
  - Poder Estadístico.
  - Poder Computacional.

# Razones Fundamentales de la Combinación

$$\mathcal{F} \subset \mathcal{A}_{\mathcal{X}}$$

$$\hat{f} : \mathcal{X} \mapsto \mathcal{A}$$

# Razones Fundamentales de la Combinación


A diagram illustrating the relationship between a family of functions  $\mathcal{F}$  and its elements. A green curved arrow points from the expression  $\mathcal{F} \subset \mathcal{A}_{\mathcal{X}}$  to the set  $\mathcal{F} = \{\hat{f}_1, \dots, \hat{f}_{\mathcal{X}}\}$ . Below the arrow, the mapping  $\hat{f} : \mathcal{X} \mapsto \mathcal{A}$  is shown.

$$\mathcal{F} \subset \mathcal{A}_{\mathcal{X}}$$
$$\mathcal{F} = \{\hat{f}_1, \dots, \hat{f}_{\mathcal{X}}\}$$
$$\hat{f} : \mathcal{X} \mapsto \mathcal{A}$$

# Razones Fundamentales de la Combinación


$$\mathcal{F} \subset \mathcal{A}_{\mathcal{X}}$$
$$\mathcal{F} = \{\hat{f}_1, \dots, \hat{f}_{\mathcal{X}}\} \quad \hat{f} : \mathcal{X} \mapsto \mathcal{A} \quad \mathcal{A}_{\mathcal{X}} = \{a_1, \dots, a_{\mathcal{X}}\}$$

# Razones Fundamentales de la Combinación






# Razones Fundamentales de la Combinación



$\mathcal{F}$ 


## Poder Estadístico



- Puede que el espacio de acción sea muy grande como para que una función singular la capture.

$\mathcal{F}$ 


## Poder Estadístico



- Puede que el espacio de acción sea muy grande como para que una función singular la capture.
- Múltiples modelos pueden arrojar resultados similares en cuanto a exactitud en el conjunto de entrenamiento.

$\mathcal{F}$ 


## Poder Estadístico



- Puede que el espacio de acción sea muy grande como para que una función singular la capture.
- Múltiples modelos pueden arrojar resultados similares en cuanto a exactitud en el conjunto de entrenamiento.
- Incurrimos en riesgo de falsos positivos del modelo en nuevos datos.

$\mathcal{F}$ 


## Poder Estadístico



- Puede que el espacio de acción sea muy grande como para que una función singular la capture.
- Múltiples modelos pueden arrojar resultados similares en cuanto a exactitud en el conjunto de entrenamiento.
- Incurrimos en riesgo de falsos positivos del modelo en nuevos datos.
- Mediante ensambles heterogéneo podemos generar una función de búsqueda más compleja

$\mathcal{F}$ 


## Poder Estadístico



- Puede que el espacio de acción sea muy grande como para que una función singular la capture.
- Múltiples modelos pueden arrojar resultados similares en cuanto a exactitud en el conjunto de entrenamiento.
- Incurrimos en riesgo de falsos positivos del modelo en nuevos datos.
- Mediante ensambles heterogéneo podemos generar una función de búsqueda más compleja

$\mathcal{F}$ 


## Poder Estadístico



- Puede que el espacio de acción sea muy grande como para que una función singular la capture.
- Múltiples modelos pueden arrojar resultados similares en cuanto a exactitud en el conjunto de entrenamiento.
- Incurrimos en riesgo de falsos positivos del modelo en nuevos datos.
- Mediante ensambles heterogéneo podemos generar una función de búsqueda más compleja

# Poder Representacional

A




- En muchas tareas de Machine Learning tenemos una hipótesis de trabajo que es desconocida.



# Poder Representacional


A



- En muchas tareas de Machine Learning tenemos una hipótesis de trabajo que es desconocida.
- Esta no puede ser representada completamente por una hipótesis de acción específica.

# Poder Representacional


A



- En muchas tareas de Machine Learning tenemos una hipótesis de trabajo que es desconocida.
- Esta no puede ser representada completamente por una hipótesis de acción específica.

# Poder Representacional


A



- En muchas tareas de Machine Learning tenemos una hipótesis de trabajo que es desconocida.
- Esta no puede ser representada completamente por una hipótesis de acción específica.
- Mediante la combinación de algoritmos, logramos la expansión del espacio de funciones representables.

# Poder Representacional


A



- En muchas tareas de Machine Learning tenemos una hipótesis de trabajo que es desconocida.
- Esta no puede ser representada completamente por una hipótesis de acción específica.
- Mediante la combinación de algoritmos, logramos la expansión del espacio de funciones representables.

# Poder Representacional


A



- En muchas tareas de Machine Learning tenemos una hipótesis de trabajo que es desconocida.
- Esta no puede ser representada completamente por una hipótesis de acción específica.
- Mediante la combinación de algoritmos, logramos la expansión del espacio de funciones representables.

# Poder Computacional


$$\mathbb{E}[\ell(\theta)]$$



- Algunos algoritmos de instancia única pueden sufrir de ineficiencia en el proceso de optimización.

# Poder Computacional


$$\mathbb{E}[\ell(\theta)]$$



- Algunos algoritmos de instancia única pueden sufrir de ineficiencia en el proceso de optimización.
- Al ensamblar múltiples modelos, podemos evaluar el comportamiento de la superficie de optimización en múltiples puntos.

# Poder Computacional

$$\mathbb{E}[\ell(\theta)]$$



- Algunos algoritmos de instancia única pueden sufrir de ineficiencia en el proceso de optimización.
- Al ensamblar múltiples modelos, podemos evaluar el comportamiento de la superficie de optimización en múltiples puntos.
- De esta manera, el proceso permite evitar el problema de estacionarse en un mínimo local en nuestra superficie de la función de pérdida.



# Mecanismos de Voto


# Rudimentos

- A grandes rasgos, el proceso de votación se puede reducir a los siguientes pasos:
  - Entrenar cada modelo por sí solo y preservar las predicciones
  - Promediar las predicciones siguiendo algún esquema.
- La promediación de predicciones responde a la siguiente estructura:
  - Tipo del vector objetivo.
  - Mecanismo de decisión.
- Para un problema de **regresión**, el mecanismo es un promedio.
- Para un problema de **clasificación**, el mecanismo puede ser mayoría simple o relativa.
- Ambos enfoques se pueden ponderar mediante la relevancia del modelo, la cual es un criterio de investigador.

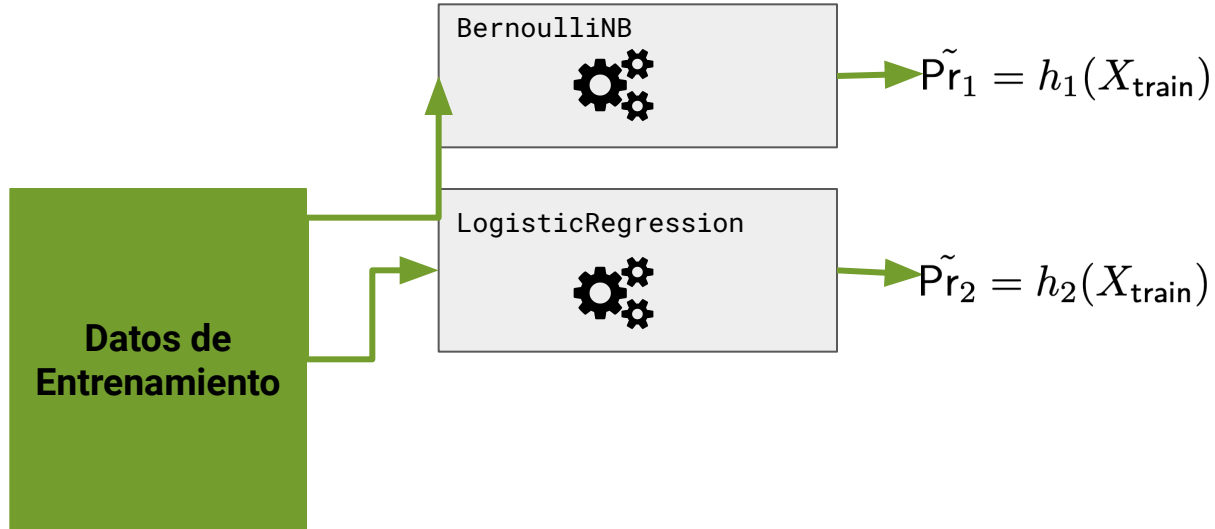
# Mecanismo de votación

Datos de  
Entrenamiento

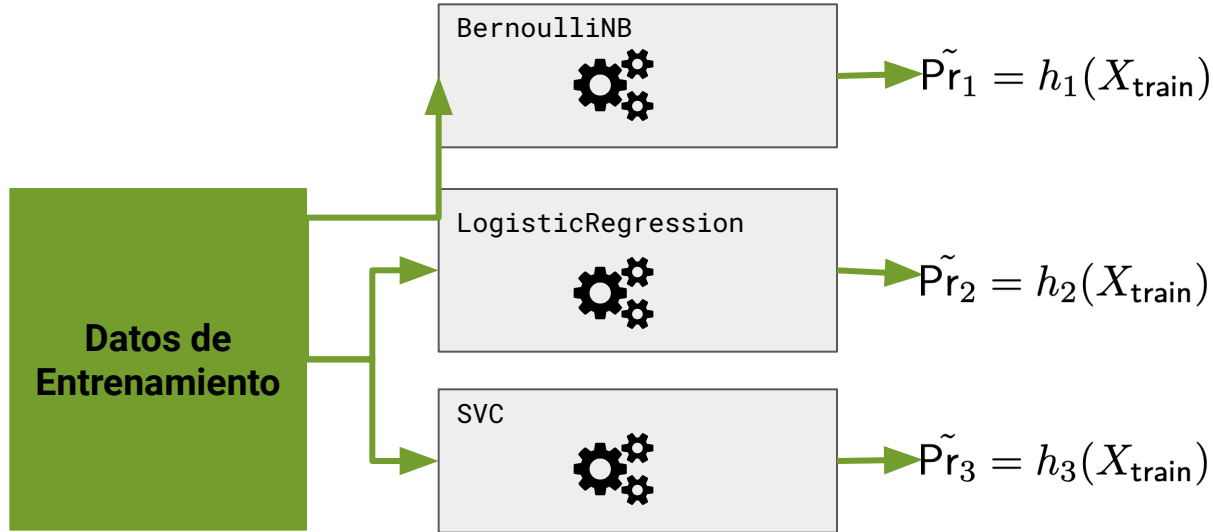
# Mecanismo de votación



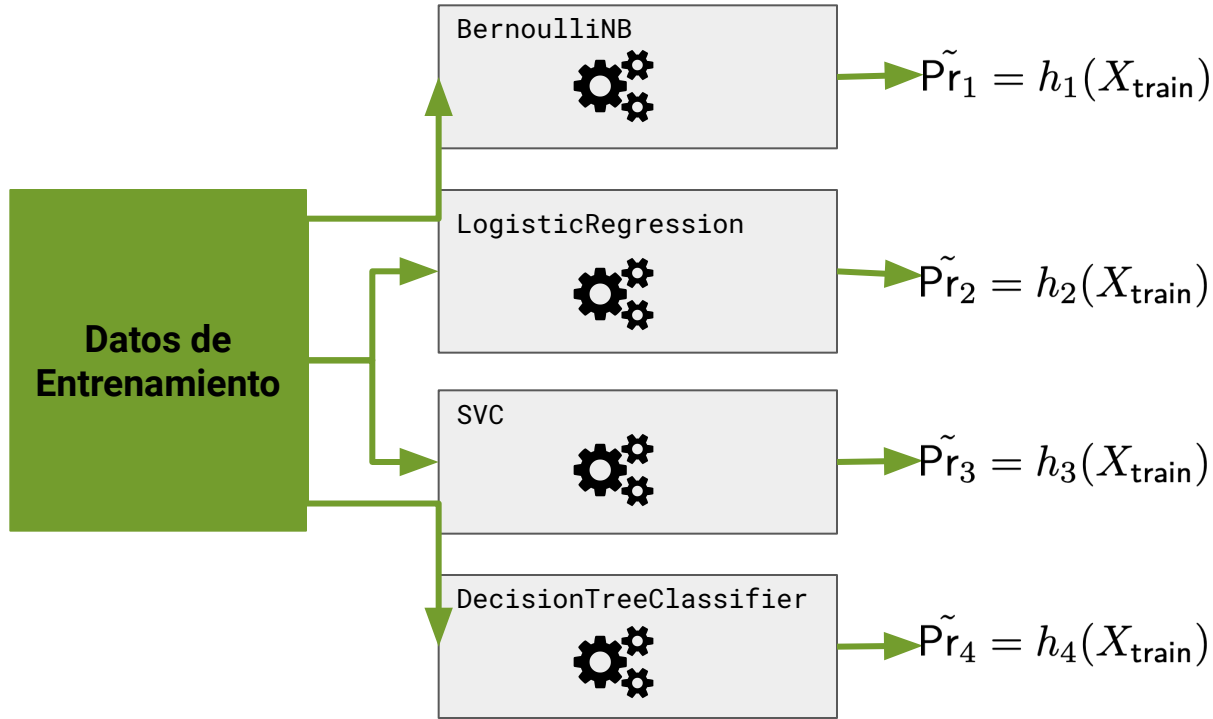
# Mecanismo de votación



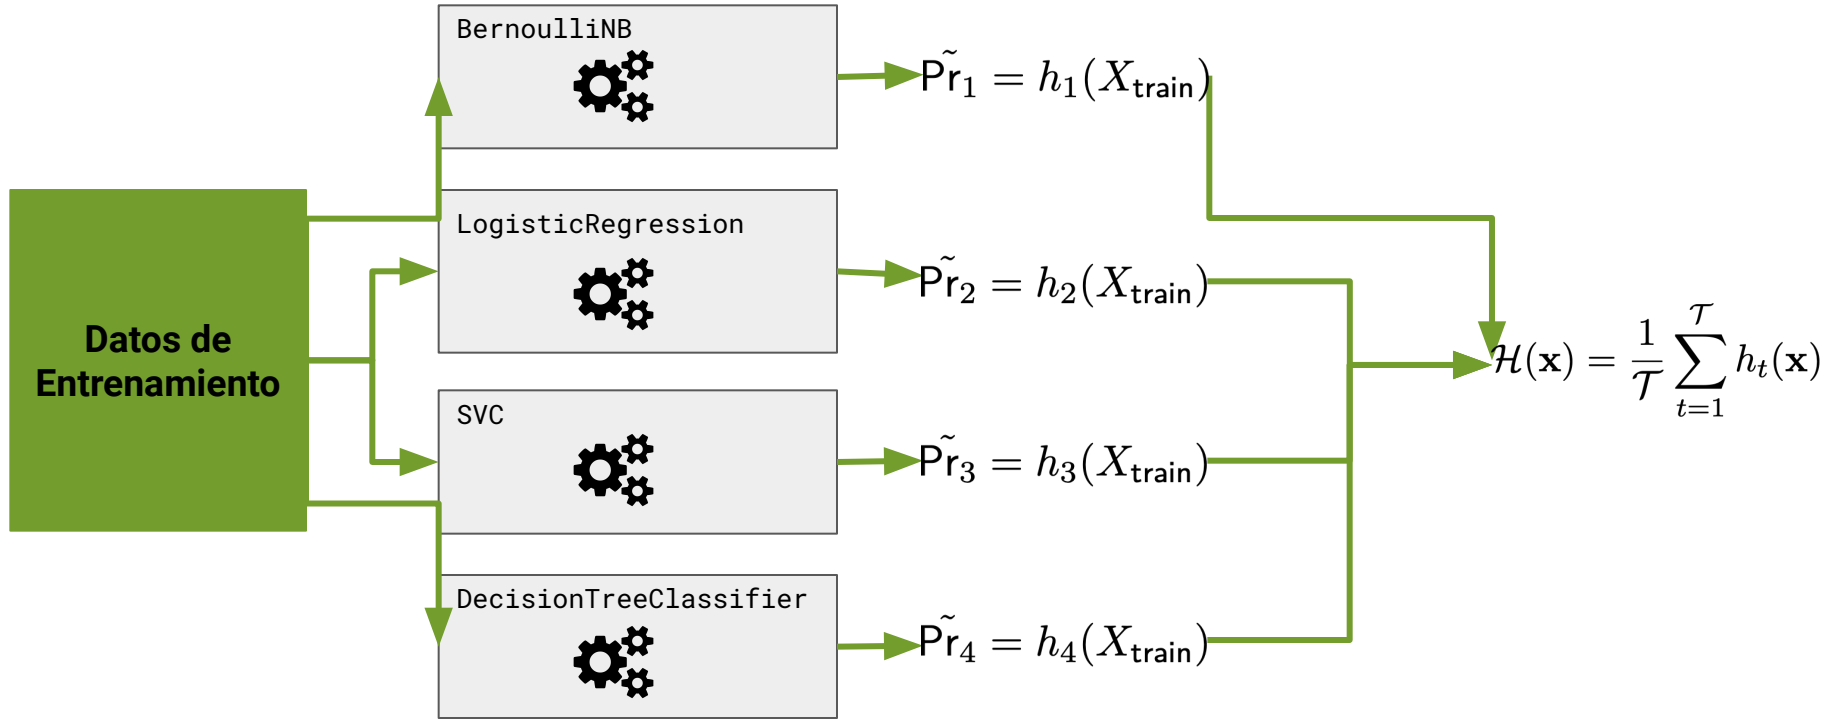
# Mecanismo de votación



# Mecanismo de votación



# Mecanismo de votación





## Comité con vector objetivo continuo

$$\mathcal{H}(\mathbf{x}) = \frac{1}{\mathcal{T}} \sum_{t=1}^{\mathcal{T}} h_t(\mathbf{x})$$

- La estrategia más común es implementar un promedio simple en las predicciones realizadas.

## Comité con vector objetivo continuo

$$\mathcal{H}(\mathbf{x}) = \frac{1}{\mathcal{T}} \sum_{t=1}^{\mathcal{T}} h_t(\mathbf{x})$$

$$h_t(\mathbf{x}) = f(\mathbf{x}) + \varepsilon_t(\mathbf{x}), \quad \forall t \in \mathcal{T}$$

- La estrategia más común es implementar un promedio simple en las predicciones realizadas.
- Parte de las virtudes de implementar un ensamble heterogéneo es el hecho de desagregar el valor final en dos partes.

## Comité con vector objetivo continuo

$$\mathcal{H}(\mathbf{x}) = \frac{1}{\mathcal{T}} \sum_{t=1}^{\mathcal{T}} h_t(\mathbf{x})$$

$$h_t(\mathbf{x}) = f(\mathbf{x}) + \varepsilon_t(\mathbf{x}), \quad \forall t \in \mathcal{T}$$

- La estrategia más común es implementar un promedio simple en las predicciones realizadas.
- Parte de las virtudes de implementar un ensamble heterogéneo es el hecho de desagregar el valor final en dos partes.
- Tendremos una parte fija que representará el “valor verdadero” y un error contextual a cada miembro del ensamble.

# Comité con vector objetivo discreto

El primer punto a considerar es si vamos a promediar clases u etiquetas.

$$\mathcal{H}(\mathbf{x}) = \frac{1}{\mathcal{T}} \sum_{t=1}^{\mathcal{T}} h_t(\mathbf{x})$$

# Comité con vector objetivo discreto

El primer punto a considerar es si vamos a promediar clases u etiquetas.

Si promediamos etiquetas, el resultado provendrá de la probabilidad específica de ocurrencia para una clase.

$$\mathcal{H}(\mathbf{x}) = \frac{1}{\mathcal{T}} \sum_{t=1}^{\mathcal{T}} h_t(\mathbf{x})$$

Etiqueta:  $h_t^c(\mathbf{x}) \in [0, 1] \rightarrow \Pr(c|\mathbf{x})$

# Comité con vector objetivo discreto

El primer punto a considerar es si vamos a promediar clases u etiquetas.

Si promediamos etiquetas, el resultado provendrá de la probabilidad específica de ocurrencia para una clase.

Si promediamos clase, el resultado provendrá de algún criterio de decisión arbitrario.

$$\mathcal{H}(\mathbf{x}) = \frac{1}{\mathcal{T}} \sum_{t=1}^{\mathcal{T}} h_t(\mathbf{x})$$

Etiqueta:  $h_t^c(\mathbf{x}) \in [0, 1] \rightarrow \Pr(c|\mathbf{x})$

**{desafío}**  
latam\_

Clase:  $h_t^c(\mathbf{x}) \in \{0, 1\}$

## Comité con vector objetivo discreto

$$\mathcal{H}(\mathbf{x}) = \begin{cases} C & \text{si } \sum_{t=1}^T h_t^j(\mathbf{x}) > \frac{1}{2} \sum_{k=1}^l \sum_{t=1}^T h_t^k(\mathbf{x}) \\ \text{rechazo} & \text{de lo contrario} \end{cases}$$

Cuando nuestro vector objetivo es discreto y nuestra estrategia es de maximización de clase con un 50%+1, podemos optar por la siguiente heurística de mayoría simple.

## Comité con vector objetivo discreto

$$\mathcal{H}(\mathbf{x}) = \operatorname{argmax}_c \sum_{t=1}^{\mathcal{T}} h_t^c(\mathbf{x})$$

Cuando nuestro vector objetivo es discreto y nuestra estrategia es de maximización de la mayor clase, podemos optar por la siguiente heurística de mayoría relativa..



## Relevancia del clasificador en el comité

$$\text{Pr}_{mv} = \sum_{k=\lceil t/2+1 \rceil}^{\mathcal{T}} \binom{\mathcal{T}}{k} \pi^k (1 - \pi)^{\mathcal{T}-k}$$

Podemos extraer la relevancia (cantidad de predicciones correctas en una decisión de ensamble) de un clasificador mediante la siguiente expresión.

## Relevancia del clasificador en el comité

$$\text{Pr}_{mv} = \sum_{k=\lceil t/2+1 \rceil}^{\mathcal{T}} \binom{\mathcal{T}}{k} \pi^k (1 - \pi)^{\mathcal{T}-k}$$

Mediante el coeficiente binomial entre la cantidad de miembros del comité (T) y clases (k), podemos ajustar la probabilidad de éxito/fracaso de un modelo específico

## Relevancia del clasificador en el comité

$$\Pr_{mv} = \sum_{k=\lceil t/2+1 \rceil}^{\mathcal{T}} \binom{\mathcal{T}}{k} \pi^k (1 - \pi)^{\mathcal{T}-k}$$

Estimamos las predicciones realizadas para la clase **específica**.

## Relevancia del clasificador en el comité

$$\text{Pr}_{mv} = \sum_{k=\lceil t/2+1 \rceil}^{\mathcal{T}} \binom{\mathcal{T}}{k} \pi^k (1 - \pi)^{\mathcal{T}-k}$$

Estimamos las predicciones realizadas para la clase **remanente**.

## Relevancia del clasificador en el comité

$$\text{Pr}_{mv} = \sum_{k=\lceil t/2+1 \rceil}^{\mathcal{T}} \binom{\mathcal{T}}{k} \pi^k (1 - \pi)^{\mathcal{T}-k}$$

Sumamos a nivel de clases estimables.

# Esquema de Ponderación

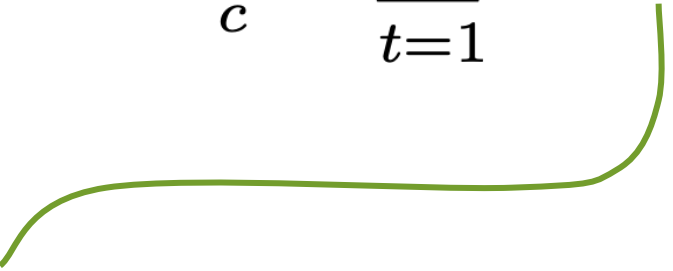
# Mecanismo de ponderación

$$\mathcal{H}(\mathbf{x}) = \operatorname{argmax}_c \sum_{t=1}^{\mathcal{T}} w_t h_t^c(\mathbf{x})$$

- Cuando nuestro modelo se guíe por mayoría absoluta (50% + 1), podemos asignar relevancia específica a cada ensamble.

# Mecanismo de ponderación

$$\mathcal{H}(\mathbf{x}) = \operatorname{argmax}_c \sum_{t=1}^{\mathcal{T}} w_t h_t^c(\mathbf{x})$$

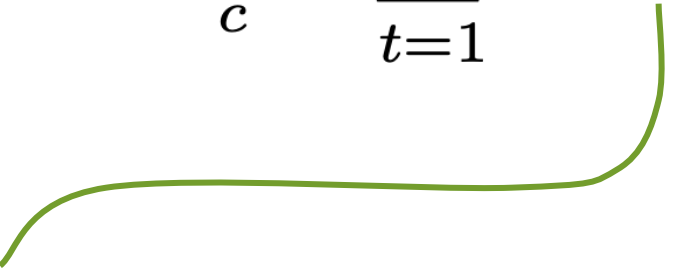
$$\sum_{i=1}^N w_i \equiv 1$$


- Cuando nuestro modelo se guíe por mayoría absoluta (50% + 1), podemos asignar relevancia específica a cada ensamble.
- Mediante la ponderación, definimos ex ante el comportamiento de cada clasificador.




# Mecanismo de ponderación

$$\mathcal{H}(\mathbf{x}) = \operatorname{argmax}_c \sum_{t=1}^{\mathcal{T}} w_i h_t^c(\mathbf{x})$$

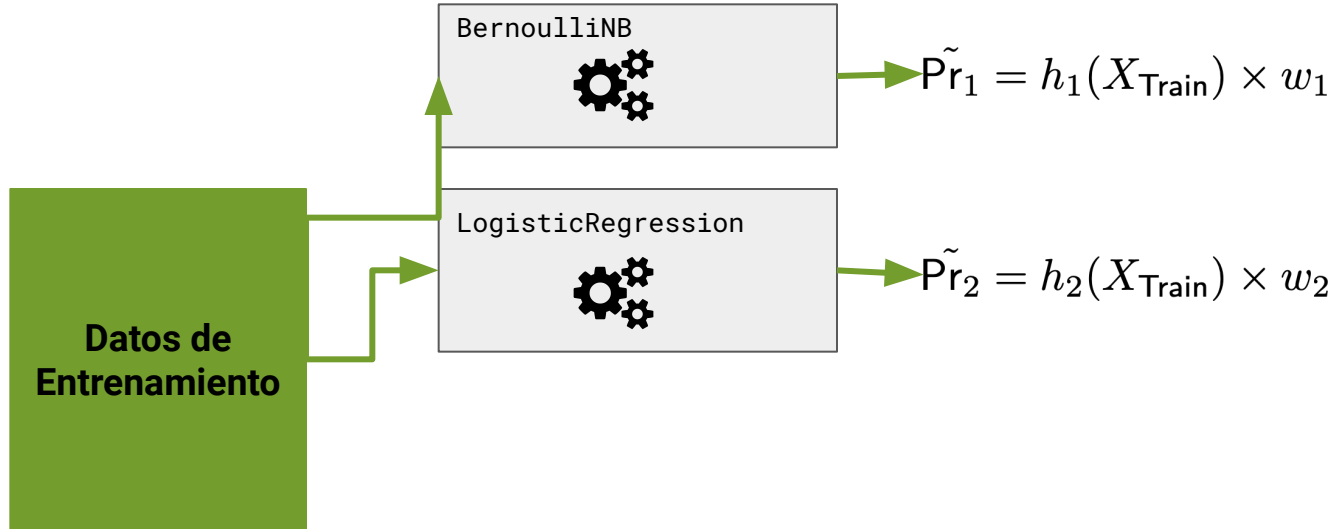
$$\sum_{i=1}^N w_i \equiv 1$$


- Cuando nuestro modelo se guíe por mayoría absoluta (50% + 1), podemos asignar relevancia específica a cada ensamble.
- Mediante la ponderación, definimos ex ante el comportamiento de cada clasificador.
- Los ponderadores usualmente deben reflejar los axiomas de Kolmogorov.

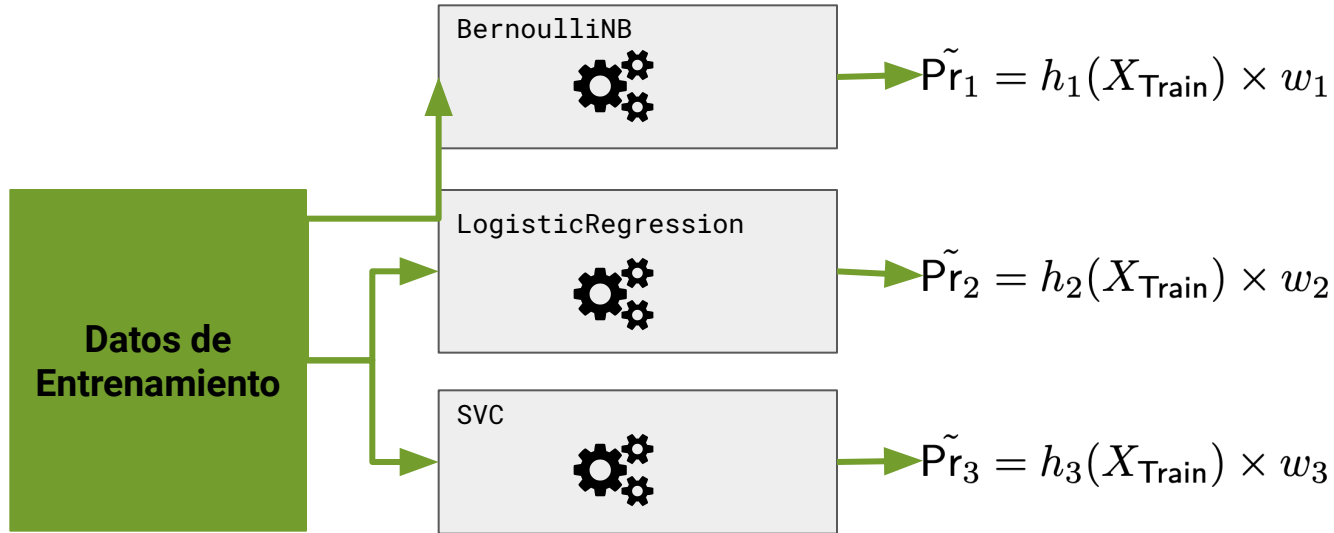
# Votación en un esquema ponderado



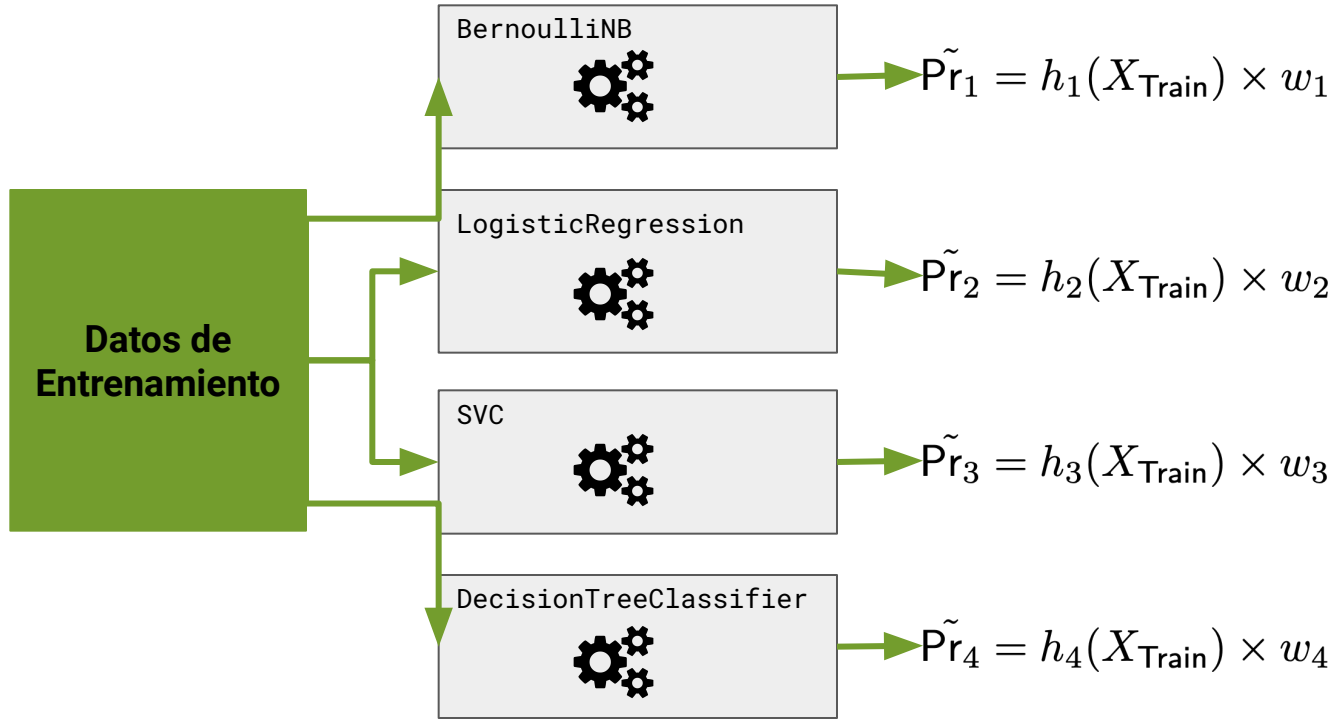
# Votación en un esquema ponderado



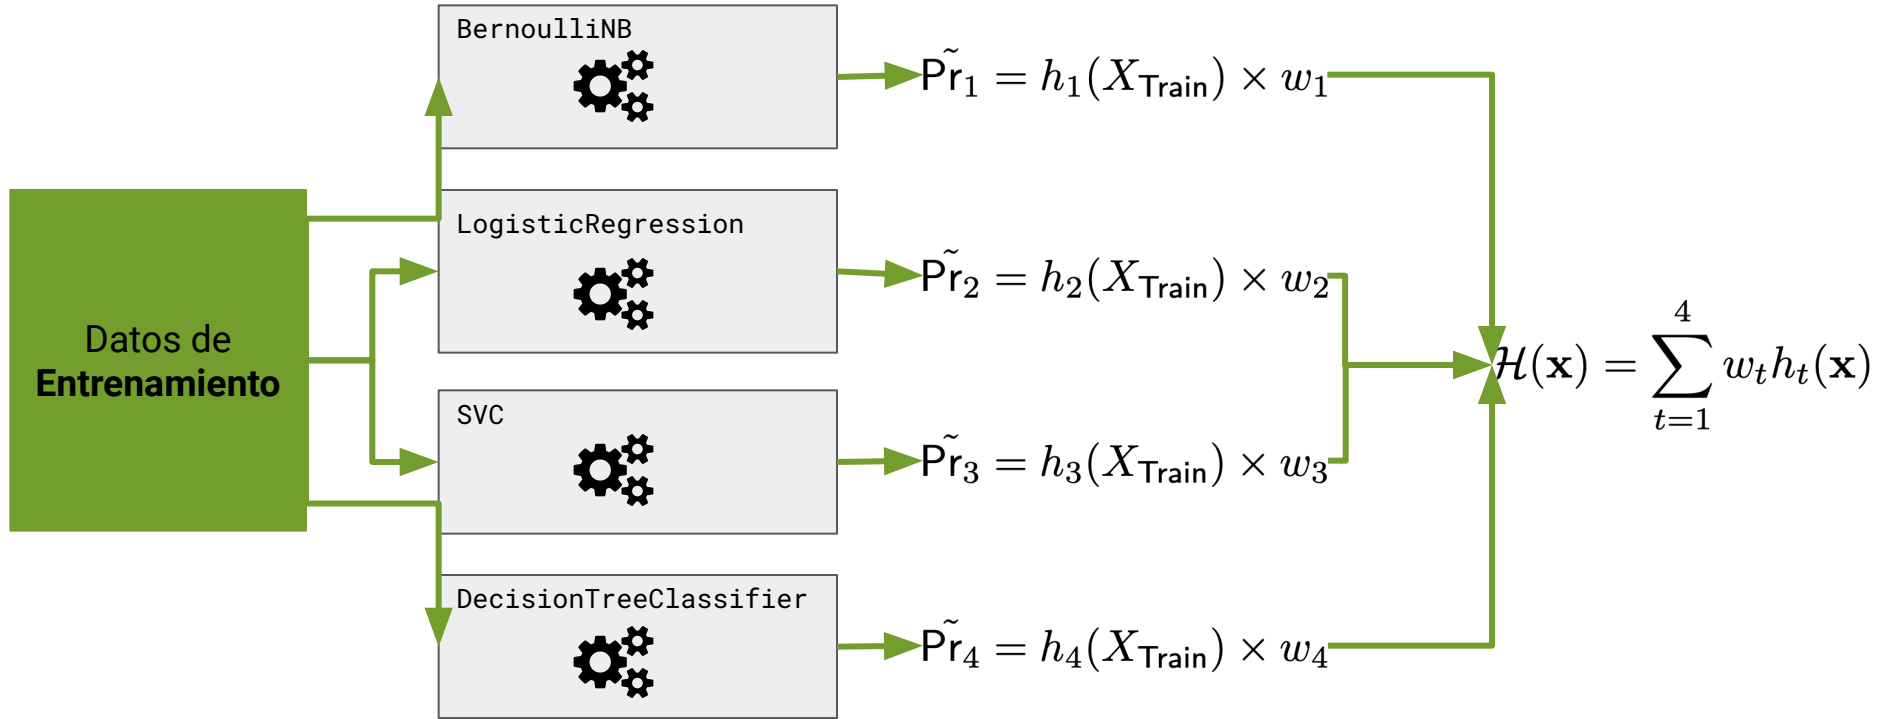
# Votación en un esquema ponderado



# Votación en un esquema ponderado



# Votación en un esquema ponderado



**{desafío}**  
**latam\_**

*Academia de  
talentos digitales*

[www.desafiolatam.com](http://www.desafiolatam.com)